

# La moda y la personalidad desde una perspectiva diferente

## *Fashion and personality from a different perspective*

Yandry Montaña, Victoria Mendoza

**Abstract**—Clothing is an important resource in people's daily lives. In addition, it also represents for some countries, a great source of economic income. For this reason, commerce is one of the activities that does not stop and that is becoming more and more important in the market, according to the advance of technology. Currently, there are already different intelligent systems that help the user to choose a set of clothes, when it comes to clothing. The recommendations that these systems give are usually based on current trends. This project aims to generate a model that is able to predict the style of dress, based on the user's personality, limited to the city of Santo Domingo de los Tsáchilas. For this purpose, models such as SVM and Neural Networks were implemented, in addition to other classification algorithms such as MLPClassifier or Random Forest, having a final accuracy of almost 70%. This result can be improved with the systematic collection of more data, since the dataset we are working with was obtained through a survey of 2209 people.

**Index Terms**—Support Vector Machine (SVM), Artificial Neural Network, Machine Learning, Classification Algorithms.

**Resumen**—La vestimenta es un recurso importante en el diario vivir de las personas. Además, también representa para algunos países, una gran fuente de ingresos económicos. Por esta razón, el comercio es una de las actividades que no se detiene y que cada vez escala más en el mercado, según el avance de la tecnología. Actualmente, ya existen diferentes sistemas inteligentes que ayudan al usuario a elegir un conjunto de ropa, cuando se trata de vestimenta. Las recomendaciones que estos sistemas dan, usualmente, están basados en las tendencias actuales. Este proyecto tiene como objetivo generar un modelo que sea capaz de predecir el estilo de vestir, en base a la personalidad del usuario, limitado en la ciudad de Santo Domingo de los Tsáchilas. Para ello, se implementaron modelos como SVM y Redes Neuronales, además de otros algoritmos de clasificación como MLPClassifier o Random Forest, teniendo un accuracy final de casi 70 %. Este resultado puede ser mejorado con la recolección sistemática de más datos, ya que el dataset con el que se trabaja, se obtuvo mediante una encuesta realizada a 2209 personas.

**Palabras Claves**—Máquina de Vector de Soporte (SVM), Redes Neuronales, Aprendizaje de Máquina, Algoritmos de clasificación.

### I. INTRODUCCIÓN

Según datos de la UNCTAD (United Nations Conference on Trade and Development) [1], se estipula que luego de la pandemia de Covid19, las actividades de comercio electrónico aumentaron considerablemente. En la primera encuesta realizada a 1819 personas de 10 nacionalidades diferentes, para determinar el impacto de la crisis sanitaria mundial, se obtuvo

como resultado que entre las 11 fuentes de consumo, donde aumentaron los compradores en línea, la moda y los accesorios se encuentran en el cuarto lugar. Así mismo, según el Informe de la moda online en España 2021 [2], las prendas de vestir se encuentran en el tercer lugar, con un 5.9 % de las ramas de mayor actividad económica, respecto al comercio electrónico de dicho país.

Con estos datos estadísticos, se puede determinar que aún en épocas de pandemia, el vestuario y la moda, también son de gran interés para los consumidores. Al ser uno de los focos que denotan impacto en la economía de algunos países, los comerciantes de moda, deben ser cada vez más ingeniosos para seguir generando ingresos. Por esta razón, con el avance de los años y la tecnología, se han implementado sistemas automatizados o asistentes virtuales que realizan sugerencias al usuario, al momento de realizar una compra.

En la mayoría de sistemas de recomendación, las sugerencias de vestimenta se realizan en base a las tendencias de moda actuales, la ubicación, las preferencias del usuario, entre otros factores. Para ello, el modelo que más predomina, según el estudio de varios artículos relacionados a este tema, son las redes neuronales, alcanzando una precisión de hasta el 97 % en sus sistemas. Y Support Vector Machine (SVM) en conjunto con otros algoritmos como K-Nearest Neighbor, regresión lineal, árboles de decisión y regresión logística binaria, alcanzan una precisión de hasta el 73 %. En este tipo de sistemas, también se usan otros algoritmos como asignación latente de Dirichlet (LDA), modelo de mezcla gaussiana (GMM), conditional similarity networks (CSN), Conditional Random Field (CRF) y Bi-LSTM.

El algoritmo de aprendizaje supervisado LDA, es utilizado para cuerpos de texto, donde se explica la similitud entre algunos datos. Su implementación referente a los sistemas de recomendación de vestimenta, se usa, por ejemplo, en el análisis de los comentarios sobre moda en internet. En cuanto al GMM, se enfoca en encontrar una curva que se ajuste a los datos del componente. Este es un algoritmo de aprendizaje no supervisado, razón por la que no se lo consideró para el sistema que proponemos. CSN [3] es también un algoritmo bastante utilizado para las recomendaciones de vestimenta, puesto que con él, se puede analizar la similitud entre imágenes para agregarlas según categorías. Por otro lado, CRF es un modelo para segmentar y etiquetar datos, pero lleva tiempo el encontrar funciones que permitan la predicción de nombres para cada etiqueta. Este tipo de algoritmos ha sido desplazado por el Deep Learning, de manera que se enfocan menos en

M. Yandry (email: ydmontano@espe.edu.ec).

M. Victoria (email: mvmendoza5@espe.edu.ec).

la ingeniería de características y se desarrollan más en el diseño e implementación de redes neurales. Bi-LSTM es uno de los algoritmos de Deep Learning que permite el aprendizaje usando entre características del pasado y futuro.

Partiendo de esta información y considerando que los algoritmos descritos en el párrafo anterior, requieren una gran cantidad de datos, se ha optado por un algoritmo de aprendizaje supervisado tradicional como SVM [4] para el algoritmo principal y Redes Neuronales, para la respectiva comparación. Estos modelos también son considerados en sistemas desarrollados hasta la actualidad, para predicciones relacionadas con la moda. La ventaja que nos ofrece SVM, es que trabaja satisfactoriamente aún sin un conjunto grande de datos. Tal es el caso de nuestro dataset, que se obtuvo por una encuesta realizada a 2209 personas, en base al estilo y la personalidad.

Las contribuciones de este trabajo es presentar los hallazgos en el proceso de limpieza y selección de datos obtenidos de encuestas, además de la implementación del modelo SVM<sup>1</sup> en comparación con las redes neuronales tradicionales, cuando no se tiene una gran cantidad de datos. Las secciones de este documento están distribuidas de la siguiente manera: (ii) Trabajos relacionados, (iii) Background, (iv) Metodología, (v) Experimentos y análisis, (vi) Resultados, (vii) Discusión y (viii) Conclusiones y trabajos futuros.

## II. TRABAJOS RELACIONADOS

Según la investigación bibliográfica realizada, los modelos que se exponen en varios de los artículos, se realiza la predicción de personalidades en base a la vestimenta. Otros trabajos también proponen formas de vestir, según las apariencias físicas o los estándares actuales de moda. Tal es el caso, de un artículo publicado por Chin-Yu Hsieh y Yung-Ming Li en 2019 [5]. Su diseño promueve un mecanismo de recomendación de vestimentas, basada en tendencias de moda y comercio social.

Para el desarrollo de este sistema, el algoritmo principal utilizado es la asignación latente de Dirichlet (LDA). Para el cálculo de las métricas resultadas de dicho sistema, utilizaron la matriz de confusión. Allí se evalúa las preferencias del usuario y tendencias, en base a las estaciones del año, la exhaustividad (recall) supera el 70 %, excepto por una estación en la que el resultado es del 0.63 %.

En otro de los artículos que relacionan estrechamente la personalidad con la forma de vestir, fue presentado en 2016 por Yan Yan, Zhiqiang Wei y Chang Wen Chen. En su documento [6], buscan inferir el tipo de personalidad en base a la forma de vestir. Su estudio fue realizado con una muestra de más de 300 personas y más de 10000 retratos, etiquetados con los tipos de personalidad. Con este modelo, comprobaron que se es capaz de predecir diferentes combinaciones de vestimenta con una precisión sobre el 50 %.

El artículo [7] publicado en 2008 por Ching-I Cheng y Damon Shing-Min Liu, propone un sistema inteligente de

búsqueda de ropa, enfocado a la creación de un asistente virtual. De esta manera, el usuario ingresa sus preferencias de vestimenta, la categoría de ropa y la ocasión para recibir sugerencias por parte del sistema. En [8] y [9] donde no se redacta la elaboración de un sistema como tal, sino más bien, una investigación bibliográfica donde se afirma que el ser humano pasa por una etapa que se la cataloga como “era del consumo emocional” y el autor hace énfasis en la relación sentimental y comunicativa que tienen las personas con las prendas de vestir que usan.

Según Ziad Al-Halah y Kristen Grauman [10], afirman que la moda de ciertas ciudades, repercuten en tiempo y espacio en otras. Ellos crean un modelo que permite predecir que tan exitoso va a ser un estilo de vestir en una determinada ciudad. En base al dataset GeoStyle. Al calcular la efectividad del modelo empleado, se utilizaron métricas como el error de previsión capturado, error absoluto medio (MAE) y error porcentual medio absoluto (MAPE). Con ello, se obtuvo que, para las recomendaciones en Vintage, se resulta un 57 % de aprobación en los estilos obtenidos. Con GeoStyle, el 80 % y en general, el 66 % de los estilos, mejoran más de un 10 % con las recomendaciones realizadas por el sistema.

En [11], se menciona otra de las perspectivas aplicables para la predicción de moda. En dicho trabajo, se toma en cuenta el estilo de vestir que se ha tenido durante grandes hitos mundiales y según los años. Wei-Lin Hsiao y Kristen Grauman en su trabajo, usan Mask R-CNN, basado en redes neuronales, para definir las articulaciones de las personas, puesto que trabajan con dataset de imágenes. Con ello, son capaces de estudiar las imágenes publicadas de personas en su vida cotidiana y con ayuda de la metadata que acompaña a dichas imágenes, el algoritmo es capaz de otorgarle una etiqueta de año a cada una de ellas.

Otro de los trabajos que usan redes neuronales para los sistemas de predicción en relación con los estilos de vestir, es el artículo [12]. Los autores usan redes neuronales para la recomendación de prendas de vestir, según los gustos de los usuarios y las tendencias. Las métricas usadas para la evaluación del modelo son el área bajo la curva y la ganancia acumulada normalizada. Con ello, se obtiene una precisión del 97.78 % para el modelo de redes neuronales, 94.60 % para el LSTM bidireccional y 94.76 % para CSN en el caso del primer dataset. Con el segundo dataset, las métricas aumentan a un 97 % y 96 % para Bi-LSTM y CSN respectivamente. Mientras, que para el modelo de redes neuronales se reducen 6 décimas.

Uno de los trabajos que presentan más que un sistema de predicción, se describe en [13], donde se redacta el funcionamiento de un “espejo mágico”, el cual, da recomendaciones de moda, tomando en cuenta las tendencias actuales, así como los gustos personales. En el desarrollo de este sistema, se utilizaron algunos algoritmos bastantes conocidos como K-Nearest Neighbor, Support Vector Machine, regresión lineal y

<sup>1</sup>We have published the source code at

árbol de decisión. En la evaluación, se determinó que el nivel de confianza del modelo es de un 95 %.

Así también, en un artículo relacionado estrechamente con la sugerencia de conjuntos en moda es [14]. En dicho trabajo se tiene como objetivo el comprender de mejor manera, los estilos de moda de la ropa. A diferencia de los demás artículos y del presente propio, este trabajo no recomienda estilos de vestir según preferencias o tendencias actuales, sino más bien, conjuntos de ropa que estén en armonía en color, textura y composición. Para llevar a cabo este sistema, hacen uso del algoritmo SVM junto con otros métodos como el FSS y BCDA. Con ello, tienen como resultado que su modelo supera más del 13 % en términos del MSE, varias líneas de base alternativas. Como finalidad, se tiene un paso intencional a la comprensión de la moda.

### III. BACKGROUND

En los sistemas desarrollados hasta la actualidad, se estudian diferentes maneras de enlazar la ropa con la personalidad, factores geográficos entre otras características. Pero hasta ahora no hemos encontrado un artículo donde, en base a la personalidad, se defina un estilo de vestir. Según los artículos relacionados a este tema, los sistemas más usados son Redes Neuronales Tradicionales y SVM, pero tras de esto, existen diversos términos que se deben considerar para entender el desarrollo de este sistema.

A continuación, se describe de manera general, aspectos más importantes de estos dos modelos, así como los hiperparámetros que utilizan para mejorar su precisión. SVM por su parte, es utilizada para la clasificación de información lineal y no lineal y la investigación de datos, basándose en la teoría estadística tradicional. El algoritmo SVM [15] permite dibujar una superficie de decisión que sirve para clasificar todo el vector de entrenamiento en subconjuntos.

Para la implementación de este modelo, se deben ajustar los parámetros según lo que requiera el modelo. En este caso, se evalúan los núcleos polinomial, Radial Basis Function (RBF) y sigmoidal. Estos son los kernels más utilizados, luego del SVM lineal [16]. La similitud entre ellos, es que utilizan las mismas características de evaluación como Gamma y regularización.

Estos, forman parte de los hiperparámetros de nuestro modelo. El siguiente parámetro es la regularización que se representa con la letra “C”. Sirve para avisarle a la optimización del SVM la cantidad de error que puede soportar. El tercer parámetro utilizado es “Gamma”. Con él, se define cuánta distancia influye en el cálculo de la línea de separación aceptable.

Por otro lado, una Red Neuronal es un método para la

resolución de problemas individuales o en combinación con otros métodos existentes. Las redes neuronales son especialmente utilizadas para extraer información y producir inferencias partiendo de un grupo de datos disponible, esto es posible gracias a la capacidad de aprendizaje que estas poseen. Estas redes son capaces de encontrar propiedades en los datos para la detección de patrones, y son altamente tolerantes a los errores.

Las redes neuronales contienen varios parámetros internos y externos. El primer parámetro es el `input_shape` o la capa de entrada, que es un tensor, el cual, se envía a la primera capa oculta [17]. Luego, se debe definir el número de capas que tendrá la red neuronal. Para ello, se utiliza el hiperparámetro `n_layers`. Una vez establecido el número de capas es necesario indicar cuántas veces se van a mandar los datos de entrenamiento a la red neuronal. El parámetro utilizado es `epochs` [18].

Ahora, es necesario definir qué tan rápido va a aprender la red neuronal. Para esto se define un “alpha”. Este es el porcentaje de aprendizaje que tendrá el modelo. Otro punto importante es la optimización de la función. Con ella, se obtienen los valores más óptimos para la red neuronal. Para poder optimizar la función es necesario establecer un algoritmo de maximización o minimización en función del objetivo. En esta función se optimizan algunos valores como el error cuadrático medio, el accuracy, el porcentaje de pérdida, entre otras [18].

### IV. METODOLOGÍA

El primer paso para el desarrollo de este proyecto, fue la recolección de datos, basada en encuestas. En un inicio se contaba con el dataset “Big Five Traits with Personality Labels”<sup>2</sup> que, según las características de personalidad basado en el test de los 5 grandes, comprobaba a que tipo de personalidad pertenece el usuario. Las entradas de este dataset son la edad, el género, la apertura, el neuroticismo, la extraversión, la conciencia y la amabilidad. La salida del mismo sería la personalidad. Esta también tiene 5 opciones de salida como lo son la personalidad seria, extrovertida, confiable, responsable y animado.

El test de personalidad de “los cinco grandes” está basado en una serie de preguntas acerca de la esencia del usuario. Con ello, se logra definir algunas características importantes del mismo y resumiendo las respuestas en 5 ítems, se puede obtener el tipo de personalidad al que pertenece. En vista de que el proyecto tiene como objetivo relacionar la moda y la personalidad, y no se encontró un dataset que contenga estas características, se optó por la formulación de una encuesta<sup>3</sup>, para de allí formar un nuevo dataset.

Las preguntas que se propusieron fueron en relación a la edad del usuario, su género, la personalidad a la que creen

<sup>2</sup>Dataset Inicial

<sup>3</sup>Encuesta

que pertenecen y el estilo de vestir que más les gusta. Para la personalidad, se utilizaron las descritas anteriormente en el primer dataset, mientras que para los estilos, las categorías han sido clasificadas según un artículo publicado la conferencia internacional sobre Aprendizaje Automático y Cibernética en 2008 [7].

La encuesta no tuvo ninguna ponderación, simplemente se definió las preguntas como obligatorias, para asegurarnos que no queden campos vacíos. La entrada de la edad es un dato de texto, pero se especifica que se debe escribir la edad en números. Por otro lado, el género, la personalidad y el estilo de vestir, son respuestas de varias opciones. Para que la persona tenga noción sobre lo que se trata cada tipo de personalidad, se elaboró una breve descripción de cada una, antes de la pregunta. Así mismo, para las categorías de vestir, se representó cada estilo con un número del 1 al 10.

Cabe mencionar que la encuesta fue aplicada a una población de 2209 personas en la ciudad de Santo Domingo de los Tsáchilas. A pesar que se llegaron a recolectar dicha cantidad de datos, al final este número disminuirá. Esto se debe a que al procesar los datos, se segmentará la muestra tomada, según las edades de entre 17 y 30 años. Este rango de valores es considerado según el primer dataset, donde también consideran el intervalo de edad mencionado y en el cual, nos basamos para el desarrollo de este modelo.

Luego de haber recolectado los datos, estos debieron ser sometidos a diferentes técnicas para pre procesarlos. Como primer paso, se tuvo que comprobar que el dataset no tuviera valores nulos. Luego, se eliminaron los registros que no eran importantes a nuestro modelo. Es decir, en el objetivo de este proyecto, se mencionaba que la muestra de estudio se define por la edad de las personas de entre 17 y 30 años. Por esta razón, se tuvo que excluir los datos que estaban fuera de este rango con la implementación de binning adaptativo. Este algoritmo separa los números en diferentes intervalos, según lo sugiera el programador.

Posteriormente, se analizaron las distribuciones de todos los valores de entrada y los de salida. Pero, para poder graficarlos, tuvimos que transformar las variables categóricas a numéricas de forma genérica con el uso de la función “map()”. Ya con las variables transformadas y las gráficas de distribuciones realizadas, se calculó también el valor de significancia de la prueba “p\_value”. Con este último valor, se puede determinar si efectivamente una variable tiene una distribución normal o no.

Luego de este análisis, comprobamos que ninguna de las variables tenía una distribución normal. Así que, para verificar la correlación entre las características de entrada con las de salida, se utilizó el método spearman; dando como resultado valores negativos, en la relación entre ciertas variables. De esta manera, se definió que la variable más importante para

realizar la predicción y la única que tiene una correlación con la variable de salida, es la personalidad.

Todo este proceso realizado, se puede considerar como la selección de características para nuestro modelo. Por lo tanto, al final se tiene una sola variable de entrada, compuesta por 5 opciones y una variable de salida, compuesta por 10 opciones. Pero, aquí se presentó otro problema. Al tener varias opciones de salida y tan pocos datos, los modelos no eran capaces de predecir correctamente. En redes neuronales, por ejemplo, el valor de pérdida aumentaba drásticamente, mientras que el accuracy se mantenía en porcentajes bajos entre 6 % y 23 %.

En consecuencia de dichos resultados, se graficó un histograma con las opciones de salidas para comprobar las que tenían menos registros. Como se muestra en la figura 1, existen algunas opciones de salida que no llegan ni a los 100 registros. De esta manera, se eliminaron 8 salidas, quedando solo dos opciones en nuestra variable Y. Habiendo pasado todos los filtros, se eliminaron las columnas que no tienen relación con la variable de salida y se procedió con la transformación correcta de los datos.




Fig. 1. Histograma de la frecuencia de valores en la variable de salida.

Para la “personalidad”, que es una variable de tipo categórico, se utilizó One Hot Encoding para transformarla a números. Cabe mencionar que esta técnica separa las opciones de la variable, en diferentes columnas. Luego, para nuestra variable de salida, que ya era un dato numérico, se utilizó la técnica de normalización para tener todo el dataset en un solo intervalo de valores. Ya con los datos transformados, se guardó el nuevo dataset en un archivo plano.

El modelo principal utilizado en este proyecto es SVM. Este algoritmo de clasificación, permite separar las salidas de predicción en dos grupos mediante un hiperplano. Para mejorar el porcentaje de precisión en la predicción, se implementa también, una función que comprende los parámetros como la regularización y gamma. Así pues, se define el modelo a utilizar en las siguientes líneas:

```
param grid = {'C': [0.1, 1, 10, 100],
              'gamma': [1, 0.1, 0.01, 0.001],
              'kernel': ['sigmoid', 'rbf'],
```



```
'poly', 'linear']}]

grid = GridSearchCV(SVC(),
                    param_grid, refit=True,
                    verbose=2)
grid.fit(X_train, y_train)
```

Luego de obtener el resultado de entrenamiento del algoritmo, se evalúa el modelo mediante las métricas de accuracy, precisión y recall. Con los porcentajes de estas tres métricas, es posible tener un conocimiento más acertado del promedio de rendimiento del modelo. Estas tres métricas serán evaluadas en todos los modelos desarrollados para posteriormente hacer su respectiva comparación. Por lo tanto, la metodología propuesta para este proyecto, se representa en la figura 2

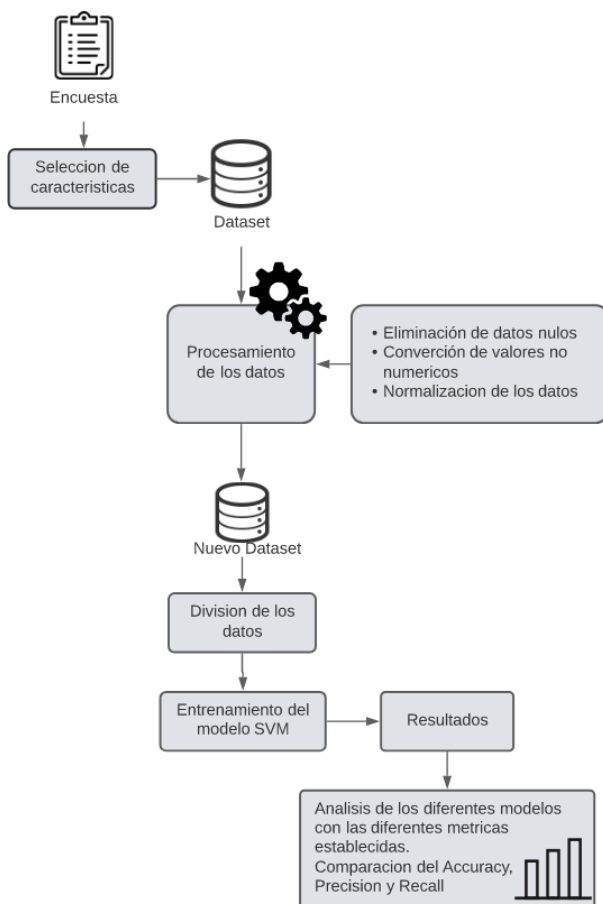


Fig. 2. Flujograma de la metodología aplicada.

## V. EXPERIMENTOS Y ANÁLISIS

En el desarrollo de este proyecto, se realiza la comparación del modelo principal SVM y Redes Neuronales. Tanto para el primer, como para el segundo algoritmo, luego de definir X e Y, se separaron los conjuntos de datos de entrenamiento (70 %) y de testing (30 %). A partir de este paso, los detalles para cada modelo cambian. En el caso de SVM, se comparan

los 4 kernels más utilizados: polinomial, sigmoidal, linear y RBF. Para analizar paralelamente estos núcleos, se creó una función que contiene a cada uno de ellos. Luego, declaramos un “for” que realiza las iteraciones respectivas pasando por los kernels especificados. Dentro de cada iteración, se entrena al modelo y se imprime una matriz de resultados. De esta manera, se tiene el accuracy aproximado con cada kernel.

Para mejorar dichos resultados, se declaró la variable “param\_grid” que contiene los hiper parámetros más comunes del SVM; el parámetro de regularización C, y gamma. Ya con estos datos, volvimos a entrenar el modelo, mejorando así, el porcentaje de accuracy. Ahora bien, para comprobar que el modelo está entrenado correctamente, se aplica la validación cruzada. Esta técnica consiste en entrenar y evaluar al modelo en diferentes secciones, según lo especifique el programador. En este caso, el dataset de entrenamiento se dividió en 3 secciones; este número también depende de la cantidad de datos que tenemos en nuestro conjunto. Al contar simplemente con 748 datos, no es recomendable asignarle un valor tan alto de secciones.

Luego de todo este proceso, se realiza la evaluación del modelo con las métricas de accuracy, precisión y recall. En la figura 3, se puede observar que, en la matriz de confusión, nuestros datos más elevados (93), pertenecen a los verdaderos positivos. Seguido de los verdaderos negativos, que constan con un total de 62 datos. Con estos resultados, comprobamos que el modelo implementado es capaz de predecir los datos con un 68,89 % de precisión.




Fig. 3. Matriz de confusión del modelo SVM.

SVM al ser uno de los algoritmos más básicos en cuanto al aprendizaje supervisado, es sencillo de implementar. Sin embargo, cuando se está aprendiendo a manipular los algoritmos de machine learning, por más simples que sean, se debe tener mucho cuidado con los tipos de datos que se ingresan. Al tratarse de un algoritmo de clasificación, sus salidas deben estar presentadas solo por dos opciones. Lo contrario a lo que realizamos en un inicio, implementando una salida de 10 opciones. Lo mismo se analizó al implementar otros algoritmos de clasificación como Random Forest Classifier o MLPClassifier, donde se obtuvieron valores más óptimos, solo

utilizando dos opciones en la variable de salida. Sin embargo, ninguno de estos algoritmos superó el 70 % de accuracy en su evaluación.

Cabe mencionar también, que aunque en la selección de características, la variable `edad` "género" no tenían una correlación con la variable de salida, se realizó igualmente el proceso para la implementación del modelo considerando estas 2 características restantes. A pesar de eso, el modelo donde se utilizaba solo una característica de entrada, superó por muy poco a este segundo ejercicio.

Para la comparación del modelo SVM, también se implementó un algoritmo con Redes Neuronales<sup>4</sup>. para la implementación de este modelo se utilizaron varias librerías como Keras, sklearn, numpy, seaborn, entre otras. Para el modelo se utilizaron datos que fueron procesados y transformados con anterioridad. Estos datos son leídos y etiquetados en un dataframe, este dataframe contiene 6 columnas y un total de 749 registros. Una vez tomado los datos se procede a realizar la división de ellos, para esto se ocupará un 70 % de los datos para el entrenamiento del modelo y el 30 % para la evaluación del modelo. En la red neuronal se definen varios aspectos como el tipo de modelo que este tendrá, el modelo escogido es el secuencial este modelo es uno de los mas utilizados debido a la conexión que establece entre las neuronas, permitiendo encontrar patrones fácilmente con una alta precisión.

Otro aspecto importante para definir es el numero de neuronas y capas a ser utilizadas en el modelo, este numero puede variar en función del numero de datos de entrada y salidas que posean los datos. Para este caso los datos que poseemos tiene 1 sola característica dividida en 5 columnas, estas columnas corresponden a las 5 personalidades presentes en el dataset, por lo tanto, la primera capa del modelo tendrá una dimensión de entrada de "5" y el mismo numero de neuronas con el método de activación de Relu. Se añade una segunda capa, esta capa tendrá solo una neurona, ya que esta es la capa de salida, por lo tanto, solo tendremos una respuesta. Debido a que los posibles resultados de salida solo son 2, pueden ser 0 y 1. La segunda capa tomara una función de activación Sigmoid.

Debido a que este ejercicio es un problema de clasificación binaria, es muy importante utilizar esta función de activación, además de que con esta función nos permitirá sacar la función de pérdida "binary\_crossentropy". Ahora se define los aspectos de compilación del modelo, para este parte se definieron 3 parámetros, la función de pérdida, el cual se menciona anteriormente que es el de "binary\_crossentropy". El algoritmo o función de optimización empleado en el modelo es el de Adam, el cual es una de las funciones empleada comúnmente obteniendo buenos resultados. Y el último parámetro definido en la compilación del modelo, son las métricas a ser evaluadas. En este punto se definen las métricas más comunes como el accuracy, la precisión y el recall.

Una vez definido el modelo de la red neuronal se procede a realizar el entrenamiento, para la función de "fit" se ingresan los datos de entrenamiento, así como el número de epochs, para este ejercicio será de 100, y el batch size el cual se estableció en 10. En la figura 4 el número de epochs representara el X, mientras que la función de perdida y el accuracy representan el Y. En este grafico se puede observar como la red neuronal aprende con el pasar del tiempo. El accuracy llega al máximo en el epochs 40, mientras que la función de perdida llega a su valor mínimo en este mismo epochs. A partir de este número la red neuronal deja de aprender y se mantiene constante.




Fig. 4. Gráfica de aprendizaje de la red neuronal.

Para la comprobación de los resultados obtenidos por la red neuronal se utilizó la matriz de confusión, esta matriz se forma a partir de los valores predichos por la red y los valores reales de los datos. Mediante esto se pueden obtener los valores verdaderos y falsos de la red. Tal como se puede observar la figura 5, el numero de valores identificado por la red correctamente es mayor que en los casos en los cuales se equivoco al identificar el estilo. Otro de los métodos para la verificación del modelo utilizado, es el método de cross validation. Mediante este método se puede comprobar el funcionamiento del modelo con varios datos. En este ejercicio se especificó en los parámetros del cross validation que realizara 3 iteraciones.




Fig. 5. Matriz de confusión de redes neuronales.

<sup>4</sup>We have published the ANN source code at

Repetiendo el mismo ejercicio, pero en lugar de tener una

sola característica de entrada, ahora tendremos 3, las cuales son la edad, el genero y la personalidad. Estas características estarán divididas en un total de 12 columnas, siendo 5 columnas para la edad, 2 para el genero y 5 para la personalidad, Por lo tanto, el número de neuronas y la dimensión de entrada en la primera capa de la red neuronal fue establecida en 12. Otro de los cambios realizados en este ejercicio fue la adición de una capa intermedia de la red. Esta capa contara con 6 neuronas y ninguna función de activación. Estos son los únicos cambios realizados al modelo para este ejercicio.

A diferencia del primer ejercicio, el accuracy máximo alcanzado se encuentra en la época 20. A partir de esta época existen pequeños aumentos del accuracy, pero en su mayoría se mantiene constante. Y de la matriz de confusión podemos observar todos los casos que fueron identificados por la matriz de confusión.

Se probaron otros modelos como la regresión logística, para este ejercicio se utilizaron los mismos datos que se encontraban preprocesados. Se estableció una sola característica de entrada el cual es la personalidad dividida en 5 columnas. Luego se procedió a dividir las columnas en variables de entrada y salida del modelo, además de realizar la partición de los datos. El 70 % de los datos fueron destinados para el entrenamiento mientras que el 30 % restando se utilizaron para la evaluación del modelo. Algunos de los hiperparametros establecidos en el modelo fueron "C" el cual representa la fuerza de penalización el cual fue establecido en 1, el numero máximo de iteraciones que realizara el modelo, y el "tol" el cual representara la cantidad de fuerza regularización que puede realizar el modelo, establecido en 0.001.

Los resultados de este modelo fueron sacados mediante una matriz de confusión. Para este modelo se saco un reporte de clasificación, en este reporte se pueden observar la precisión y el recall del modelo. Con el modelo de regresión logística se repitió el mismo ejercicio, pero con 3 características de entrada, las cuales son la edad, genero y personalidad. Se utilizaron los mismos hiperparametros para la creación del modelo, y se establecieron la matriz de confusión, y el reporte de clasificación para la evaluación del modelo.

## VI. RESULTADOS

Para el algoritmo principal SVM, aún implementando los hiper parámetros C y Gamma, se obtuvo un accuracy del 73,77 %, una precisión del 74,45 % y un recall de un 80,95 %. A pesar de que se implementaran correctamente los datos, la precisión del modelo no superó el 75 % como se había propuesto en un inicio. Los datos que utilizamos y la manera en la que se los recolectó, influyó bastante en la predicción del modelo. Además, luego de implementar los respectivos y transformación de variables, el conjunto de datos resultó aún más pequeño de lo que se tenía. En el mismo modelo

TABLA I  
ANÁLISIS COMPARATIVO DE LOS MODELO IMPLEMENTADOS CON UNA CARACTERÍSTICA

Metricas	Una característica				
	SVM	Redes Neuronales	Regresion Logistica	Random Forest	MPL Classifier
Accuracy	73.77 %	68.89 %	69.00 %	68.88 %	66.22 %
Precision	74.45 %	58.75 %	69.00 %	66.90 %	60.22 %
Recall	80.95 %	70.93 %	68.00 %	79.48 %	94.64 %

con SVM, pero usando todas las características, se obtuvo un accuracy del 68,44 %, precisión del 63,53 % y el recall de 95,83 %.

A pesar de intentar realizar el modelo con otros algoritmos, se obtuvo resultados bastante similares y cercanos al 70 % en su accuracy. Así pues, para MLPClassifier, con una sola característica de entrada, se logra un accuracy del 66,22 %, mientras que con las 3 características de entrada, se obtiene un 64,88 %. De la misma manera para Random Forest, que alcanza un accuracy del 66,22 % utilizando todas las variables de entrada y, un 68,89 % con una sola entrada.

En cuanto a las redes neuronales, podemos observar los resultados de evaluación, donde, teniendo una sola variable de entrada correspondiente a la personalidad, el modelo logra un accuracy del 68.86 %, una precisión del 58 % y el recall del 70 %. Los resultados obtenidos mediante la validación cruzada de 3 ciclos fueron de 62 %, 58 % y el 61 %. En la Tabla I se puede observar la comparación entre los 5 modelos implementados utilizando una característica de entrada. Además en la figura 6 se puede ver la tabla representada en un gráfico de barras.




Fig. 6. Métricas de los modelos con una sola característica de entrada.

Así mismo, utilizando las 3 variables de entrada, se añade una nueva capa de 6 neuronas, se puede observar que el accuracy del modelo fue del 64 %, con una precisión del 55 % y un recall del 69 %. De igual forma que en el primer ejercicio se realizó una validación cruzada usando 3 ciclos. Los resultados obtenidos por la validación fueron del 62 %, 65 % y el 57 %. En la tabla II se puede observar al comparación entre todos los modelos implementados utilizando tres características de entrada. Además en la 7

TABLA II  
 ANÁLISIS COMPARATIVO DE LOS MODELOS IMPLEMENTADOS CON TRES CARACTERÍSTICAS

Métricas	Tres características				
	SVM	Redes Neuronales	Regresión Logística	Random Forest	MPL Classifier
Accuracy	68.44 %	66.22 %	68.00 %	66.22 %	64.88 %
Precision	63.53 %	56.70 %	70.00 %	64.74 %	60.86 %
Recall	95.83 %	71.53 %	67.00 %	76.92 %	77.06 %

se pueden observar las métricas de los modelos con tres característica de entrada en una diagrama de barras.




Fig. 7. Métricas de los modelos con tres características de entrada.

## VII. DISCUSIÓN

Se realizaron varias pruebas con los datos iniciales recolectados por las encuestas. Estos datos tenían 10 posibles valores de salida y un total de 2209 registros. Al realizar el entrenamiento del modelo, los resultados obtenidos eran realmente bajos. Aún realizando diferentes pruebas con los hiper parámetros de la red neuronal, el máximo valor de accuracy obtenido era del 24 %. De la misma manera, al implementar SMV, con los 4 kernels y los dos hiper parámetros más utilizados, no se superaba el 42 % de accuracy.

Por esta razón, se volvió a realizar el análisis de los datos, tomando en cuenta su distribución, la correlación entre variables y la cantidad de opciones que se tenían en la variable de salida. Con este nuevo estudio, se determinó que existían estilos de vestir con menos de 100 registros. En consecuencia de ello, se tomaron los dos estilos de vestir con mayor cantidad de respuestas, siendo estos los estilos de casual y modesto, convirtiendo así, el ejercicio en un problema binario. Esto quiere decir que tendrá únicamente dos opciones de salida. Realizando las pruebas con el nuevo dataset el valor de accuracy del modelo aumentó hasta el 73 %.

Sin embargo, en los demás modelos implementados, se tuvo un accuracy similar que varía entre el 65 y 69 %. Support Vector Machine, nuestro modelo principal, por su parte, superó

por cerca de 4 puntos, al resto de modelos, con un accuracy del 73,77 % . Con estos resultados, podemos determinar que SVM presenta mejores características para este modelo en particular, ya que, al ser un algoritmo tradicional, no requiere de una cantidad grande de datos y además, es un modelo preciso para problemas de clasificación binaria. A diferencia de las redes neuronales, donde el entrenamiento requiere de más tiempo y más datos.

## VIII. CONCLUSIONES Y TRABAJOS FUTUROS

Al cabo de varios intentos e implementaciones de distintos modelos, se obtuvo a las Support Vector Machine, como el algoritmo más óptimo para este proyecto. El accuracy obtenido no supera por mucho a las redes neuronales, por la cantidad de datos y los resultados de las otras métricas, SVM presentó mejores características para el problema propuesto. El accuracy al final de la comparación con los demás algoritmos, llega hasta un 73 %. A pesar que no es un porcentaje tan alto, este proyecto supera al porcentaje alcanzado por los trabajos relacionados donde se implementa Redes Neuronales, SVM y Regresión Logística Binaria, lo cuales lograron hasta un 65 % de precisión en la predicción.

Para mejorar el porcentaje de predicción de este modelo, se propone como trabajo futuro, el realizar encuestas donde se haga un estudio previo de estadística, para que los datos no contengan tanto sesgo en su recolección. Además, se pretende replantear el tema, para que desde el inicio, se trate de un problema de clasificación y así, no tener tantas opciones en la variable de salida. De la misma manera, se deben recolectar más datos, ya que al hacer la limpieza y transformación de las variables, se pierden gran cantidad de datos.

## REFERENCIAS

- [1] UNCTAD, "COVID-19 has changed online shopping forever, survey shows — UNCTAD," 10 2020.
- [2] Modaes, "Informe de la moda online en España 2021," 05 2021.
- [3] A. Veit, S. Belongie, and T. Karatezos, "Conditional similarity networks," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1781–1789, 2017.
- [4] E. Galindo, "Estudio comparativo entre máquinas de soporte vectorial multiclase, redes neuronales artificiales y sistema de inferencia neuro-difuso auto organizado para problemas de clasificación," 2020.
- [5] C.-Y. Hsieh and Y.-M. Li, "Fashion recommendation with social intelligence on personality and trends," in *2019 8th International Congress on Advanced Applied Informatics (IIAI-AAI)*, pp. 85–90, 2019.
- [6] Y. Yan, Z. Wei, and C. W. Chen, "Are you what you look like? exploring correlations in personality type and their wearing," in *2016 Visual Communications and Image Processing (VCIP)*, pp. 1–4, 2016.
- [7] C.-I. Cheng and D. S.-M. Liu, "An intelligent clothes search system based on fashion styles," in *2008 International Conference on Machine Learning and Cybernetics*, vol. 3, pp. 1592–1597, 2008.
- [8] Y. Weihua, "Fashion design in emotional consumption era," in *2009 IEEE 10th International Conference on Computer-Aided Industrial Design Conceptual Design*, pp. 1524–1527, 2009.
- [9] R. Casidy, "An empirical investigation of the relationship between personality traits, prestige sensitivity, and fashion consciousness of generation y in australia," *Australasian Marketing Journal (AMJ)*, vol. 20, no. 4, pp. 242–249, 2012.



- [10] Z. Al-Halah and K. Grauman, "From paris to berlin: Discovering fashion style influences around the world," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [11] W.-L. Hsiao and K. Grauman, "From culture to clothing: Discovering the world events behind a century of fashion images," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 1066–1075, October 2021.
- [12] Z. Lu, Y. Hu, Y. Jiang, Y. Chen, and B. Zeng, "Learning binary code for personalized fashion recommendation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.
- [13] J. Fu, Y. Liu, J. Jia, Y. Ma, F. Meng, and H. Huang, "A virtual personal fashion consultant: Learning from the personal preference of fashion," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 31, Feb. 2017.
- [14] Y. Ma, "Towards Better Understanding the Clothing Fashion Styles: A Multimodal Deep Learning Approach — Proceedings of the AAAI Conference on Artificial Intelligence," 02 2017.
- [15] L. Mohan, J. Pant, P. Suyal, and A. Kumar, "Support vector machine accuracy improvement with classification," in *2020 12th International Conference on Computational Intelligence and Communication Networks (CICN)*, pp. 477–481, IEEE, 2020.
- [16] Z. A. Sunkad *et al.*, "Feature selection and hyperparameter optimization of svm for human activity recognition," in *2016 3rd International Conference on Soft Computing & Machine Intelligence (ISCMI)*, pp. 104–109, IEEE, 2016.
- [17] N. M. Aszemi and P. Dominic, "Hyperparameter optimization in convolutional neural network using genetic algorithms," *Int. J. Adv. Comput. Sci. Appl.*, vol. 10, no. 6, pp. 269–278, 2019.
- [18] C. C. Sánchez Caballero, "Optimización de hiperparámetros en redes neuronales," *Bibliotecas PUCV*, 2020.